スライド自動解説システム「NarrationAutomata」

https://github.com/takago/NarrationAutomata

October 14, 2026

目次

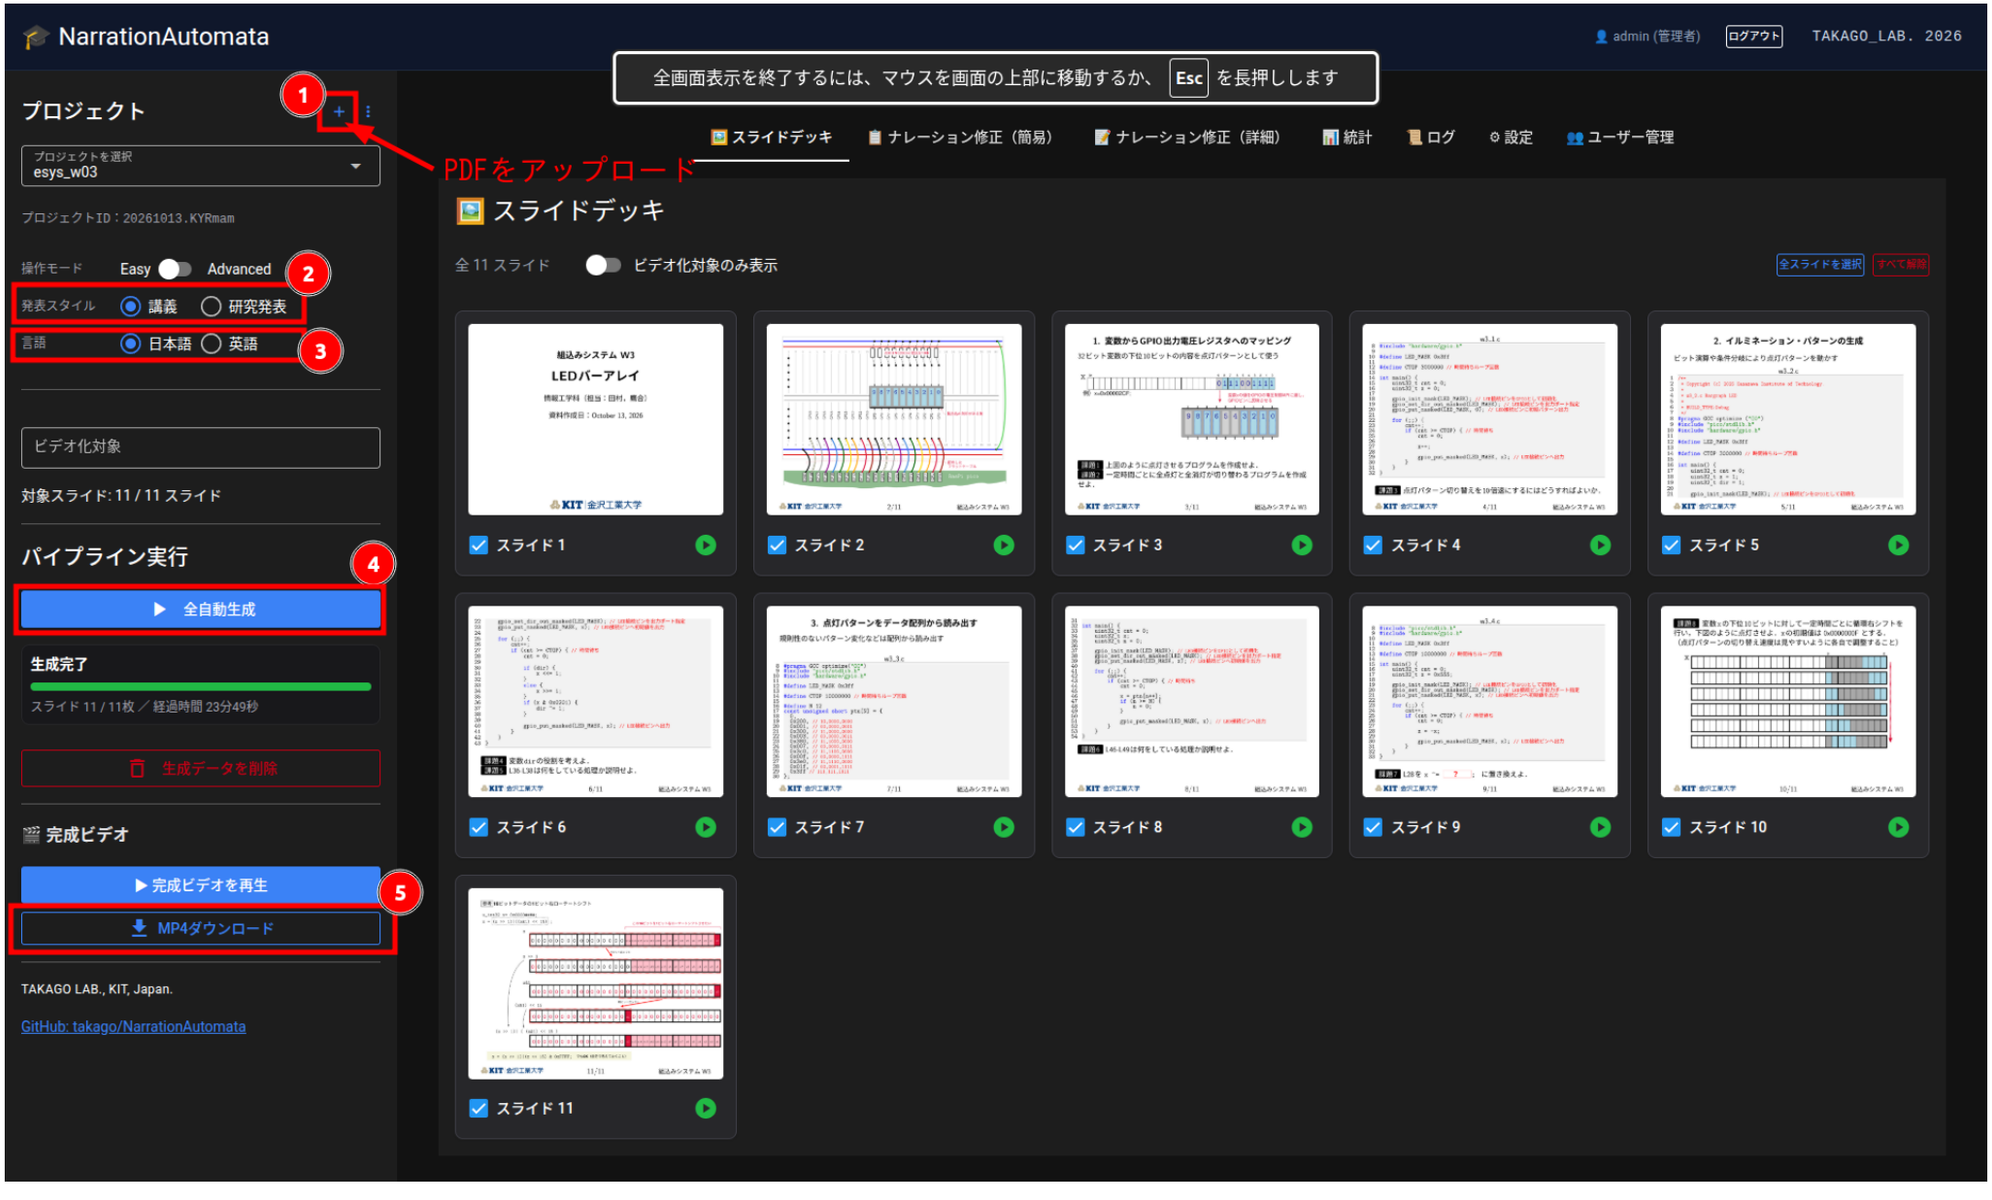
1. 特徴
2. 簡単な使い方
3. デモ
4. 仕組み

1. 特徴

- PDFスライドから音声解説付きビデオを全自動生成.
  → 利用例：学習用ビデオ．研究発表の参考.
- 全てローカル環境で動作可能.
  → 外部に公開できないスライドも扱える.
- 視線を誘導するためのレーザポインタ風マーカを表示.
- AlibaraのQwen3.8のような視覚言語モデルを利用することで，画像化されたテキストや数式を認識し，解説が可能.
- 日本語TTSで問題になりがちな漢字や専門用語のヨミを自動補正.
- 日英のナレーション音声に対応．参照音声対応のTTSを利用すれば，自分の声での読み上げも可能[1]．日英字幕を表示可能.

[1]例えば，Aratako さんの Irodori-TTS など，参照音声に対応した TTS を利用できる.

2. 簡単な使い方


NarrationAutomata
admin (管理者)
ログアウト
TAKAGO_LAB. 2026
全画面表示を終了するには、マウスを画面の上部に移動するか、 Esc を長押しします
プロジェクト
1
PDFをアップロード
プロジェクトを選択
esys_w03
プロジェクトID：20261013.KYRmam
操作モード
Easy
Advanced
2
発表スタイル
講義
研究発表
言語
日本語
英語
3
ビデオ化対象
対象スライド: 11 / 11 スライド
パイプライン実行
4
全自動生成
生成完了
スライド 11 / 11枚 ／ 経過時間 23分49秒
生成データを削除
完成ビデオ
完成ビデオを再生
MP4ダウンロード
5
TAKAGO LAB., KIT, Japan.
GitHub: takago/NarrationAutomata
スライドデッキ
ナレーション修正（簡易）
ナレーション修正（詳細）
統計
ログ
設定
ユーザー管理
全 11 スライド
ビデオ化対象のみ表示
全スライドを選択
すべて解除
スライド 1
スライド 2
スライド 3
スライド 4
スライド 5
スライド 6
スライド 7
スライド 8
スライド 9
スライド 10
スライド 11

3. デモ　– 画像に基づく解説 –



(ChatGPTによる生成画像)

3. デモ – プログラムの解説 –

serv.py

```
 1 import sys
 2 import socket
 3
 4 BIND_IP='0.0.0.0'
 5 BIND_PORT=int(sys.argv[1])
 6 print(BIND_IP,BIND_PORT)
 7
 8 lsock = socket.socket(socket.AF_INET, socket.SOCK_STREAM)
 9 lsock.setsockopt(socket.SOL_SOCKET, socket.SO_REUSEADDR, 1)
10 lsock.bind((BIND_IP, BIND_PORT))
11 lsock.listen(10)
12 while True:
13     csock, address = lsock.accept()
14     print('Hello...',address)
15     while True:
16         msg = csock.recv(4096)
17         if len(msg) == 0:
18             csock.close()
19             print('bye...',address)
20             break
21         print(msg)
22         csock.send(msg)
```

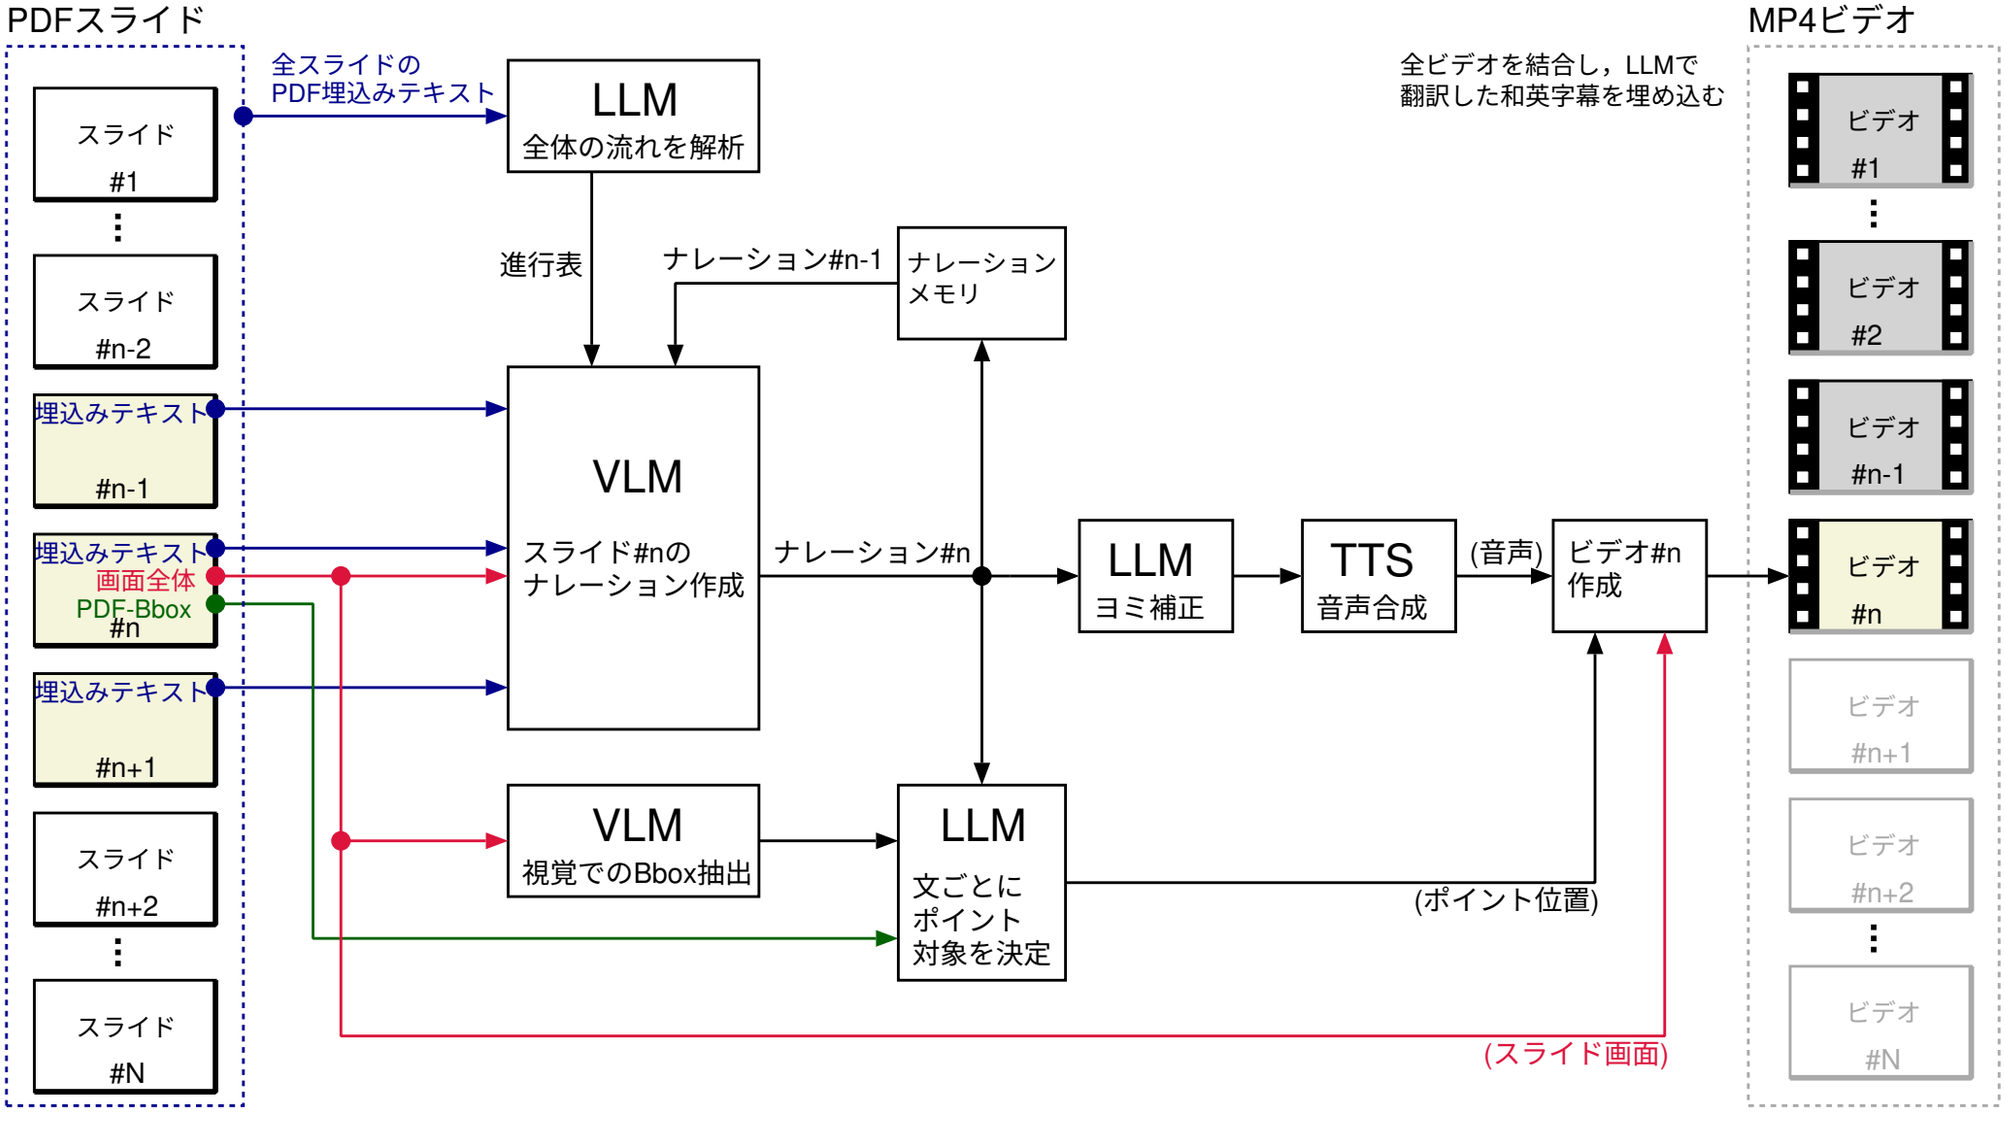
3. デモ　　– 式の解説 –

最小自乗法による最適予測係数の算出方法について説明する．p_kを線形予測係数，Kを予測次数とすると，予測残差e_mは次のように表すことができる.

$$e_m = x_m - \hat{x}_m = x_m + \sum_{k=1}^{K} p_k x_{m,k} \tag{1}$$

ここで，x_mはインデックスmの信号値$(m = 0, \cdots M-1)$，$\hat{x}_m$はx_mの予測値である．$x_{m,k}$はx_mの予測に用いられる周囲の信号値である．

4. 仕組み


PDFスライド
スライド #1
スライド #n-2
埋込みテキスト #n-1
埋込みテキスト 画面全体 PDF-Bbox #n
埋込みテキスト #n+1
スライド #n+2
スライド #N
全スライドの PDF埋込みテキスト
LLM 全体の流れを解析
進行表
ナレーション#n-1
ナレーション メモリ
VLM スライド#nの ナレーション作成
ナレーション#n
VLM 視覚でのBbox抽出
LLM 文ごとに ポイント 対象を決定
LLM ヨミ補正
TTS 音声合成
(音声)
ビデオ#n 作成
(ポイント位置)
(スライド画面)
全ビデオを結合し，LLMで 翻訳した和英字幕を埋め込む
MP4ビデオ
ビデオ #1
ビデオ #2
ビデオ #n-1
ビデオ #n
ビデオ #n+1
ビデオ #n+2
ビデオ #N